

Analisis de Datos Masivos

Trabajo Practico Integrador

Etape 1 — Problema, datos y arquitectura

Lic. Pablo Daniel Origlia

Maestria en Ciencias de Datos — UCASAL 2026

El problema que abordamos

Pregunta central

¿Cómo impactan las condiciones operativas de la flota (tipo de vehículo, conductor, incidentes, mantenimiento) **sobre los tiempos de entrega y la satisfacción del cliente** en un operador de e-commerce brasileño?

Por que este problema

- Olist expone el *resultado* logístico (demoras, reseñas) pero no las *causas* operativas
- Cruzar ambas fuentes permite pasar de descripción a causas
- Decisiones concretas: mantenimiento preventivo, asignación de rutas, gestión de conductores

Tipo de análisis previsto

- **Descriptivo**: patrones de demora por región y vehículo
- **Predictivo**: modelo de riesgo de entrega tarde (Etapas 3 y 4)
- **Prescriptivo**: recomendaciones de asignación (Etapa 4)

Arquitectura de datos

Fuente 1 — Olist

(real, Kaggle)

Tabla	Filas
olist_geolocation	1.000.163
olist_orders	99.441
olist_order_items	112.650
olist_order_reviews	99.224
olist_order_payments	103.886
olist_customers + sellers	102.536
olist_products	32.952

Fuente 2 — Flota

(sintetica calibrada)

Tabla	Filas
fleet_deliveries	96.470
fleet_incidents	3.574
fleet_maintenance	688
fleet_vehicles	60
fleet_drivers	40

Clave de vinculacion

`fleet_deliveries.order_id`
= `olist_orders.order_id`

SGBD: PostgreSQL 15 **Total:** $\approx$ 1,6 M registros **Indices:** 67 (DDL + covering indexes)

Calidad de datos — hallazgos del import

El dataset Olist presento **4 problemas conocidos** que requirieron fixes antes del import (03b_fix_constraints.sql):

Problema	Causa	Solucion aplicada
Coordenadas fuera de Brasil	42 de 1M registros en geolocation	CHECK eliminado; filtrar en Etapa 2
Productos con peso = 0	4 registros con weight_g = 0	CHECK ampliado; imputar mediana
Items con producto inexistente	Productos eliminados del catalogo	Placeholder unknown_product
review_id duplicados	814 duplicados en CSV (bug Olist)	Nueva PK interna review_pk

✓ **8 ordenes** con status='delivered' pero sin fecha real de entrega (excluir en Etapa 2) ✓ Todos los problemas **documentados** en 03c_post_import.sql y en el diccionario de

Las 5 preguntas analíticas

- ❶ **Q1** — ¿Que factores operativos (`route_risk_level`, tipo de vehiculo, `driver_behavior_score`) se asocian a las entregas demoradas, por estado de Brasil?
- ❷ **Q2** — ¿Existe relacion entre el comportamiento del conductor y el score promedio de resena del cliente?
- ❸ **Q3** — ¿En que meses se concentran los mantenimientos correctivos, y coincide con el pico de ordenes demoradas en Olist?
- ❹ **Q4** — ¿Que tipos de incidente generan mayor impacto en horas de demora?
- ❺ **Q5** — ¿El costo de mantenimiento por tipo de vehiculo se justifica con su rendimiento logistico?

Analisis de performance — EXPLAIN ANALYZE

Consulta	Exec. sin (ms)	Exec. con (ms)	Mejora	Sh. read sin	Operacion principal	Indice usado
Q1 Estado × vehiculo	184	164	-10.9%	1.496	Sort + Parallel Hash Join	ninguno
Q2 Conductor ↔ resena	145	107	-26.5%	0	Sort + Parallel Hash Join	ninguno
Q3 Estacionalidad	218	173	-20.4%	0	Sort + Hash Join	ninguno*
Q4 Incidentes	43	36	-17.0%	2	Sort + Nested Loop	idx_del_st
Q5 Costo vs. rendimiento	57	62	+8.3%	0	Merge Join	ninguno

* Q3 hace **spill a disco** (718 bloques temp): SET work_mem = '16MB' lo elimina.

Tamano de indices vs. datos: olist_orders 59 MB datos / 45 MB indices (76 %) fleet_deliveries
68 MB datos / 55 MB indices (81 %)

Que nos dice el planner

Lo que observamos

- El planner uso Seq Scan en 4 de 5 consultas aunque los covering indexes existian
- Unico indice activo: `idx_del_status` (Bitmap Scan, 624 kB, Q4)
- Q3 hace spill a disco por `work_mem` insuficiente (4 MB default)
- Q5 **empeora** 8 % con mas indices (overhead de planning)

Por que importa

- Cuando un filtro devuelve $>10-15\%$ de las filas, el Seq Scan paralelo gana al Index Scan
- Mas indices $\neq$ mejor performance
- Los covering indexes de Secciones A-E entraran en accion en Etapa 2 (dataset analitico, mayor selectividad)
- El indice con mejor relacion tamano/impacto del proyecto: `idx_del_status` (Bitmap Scan)

Aprendizaje central

El optimizador de PostgreSQL elige correctamente entre Seq Scan e Index Scan segun el

Entregables de Etapa 1

Completados ✓

- Base de datos cargada (PostgreSQL 15)
- DDL con constraints, FKs y 67 indices
- Fix de 4 problemas de calidad del dataset
- Script de generacion de flota sintetica (`generate_fleet_dataset.py` v1.1)
- 5 consultas analiticas con EXPLAIN ANALYZE (sin y con indices)
- Analisis de performance documentado
- Diccionario de datos v2 (14 tablas, 14 KPIs, relaciones)

Anticipaciones para Etapa 2

- Diagnostico de calidad listo (03c): coordenadas invalidas, pesos nulos, duplicados en reviews, 8 ordenes sin fecha
- Indices F1 y F2 creados anticipadamente para el JOIN principal del dataset analitico
- Variables objetivo ya definidas:
eta_variation_hours (regresion)
delivery_status (clasificacion)

Repositorio

github.com/pablo-origlia/

Maestría en Ciencias de Datos — UCASAL 2024

Dataset analitico

- 1 Imputar pesos nulos (mediana por categoria)
- 2 Filtrar coordenadas fuera de Brasil
- 3 Excluir 8 ordenes sin `delivery_date`
- 4 Construir el JOIN principal:
14 tablas → 1 dataset analitico

Analisis exploratorio (EDA)

- Distribucion de `eta_variation_hours`
- Correlacion conductor ↔ `resena`
- Estacionalidad de mantenimientos nov-dic
- Segmentacion por tipo de vehiculo y region

