

Trabajo Practico Integrador

Etapas 1: Problema, datos y arquitectura

Lic. Pablo Daniel Origlia

Profesor Dr. Rafael Visa
159 Análisis de Datos Masivos
Maestría en Ciencias de Datos - UCASAL - Octubre 2026

Presentación de avance de la Etapa 1 del TPI. Duración: 5-7 minutos. Estructura: problema que abordamos (1 slide), arquitectura de datos (1 slide), hallazgos del import (1 slide), las 5 preguntas analíticas (1 slide), resultados de performance (2 slides) y cierre con lo que viene (1 slide). Total: 8 slides sin contar portada.

El problema

Pregunta central

¿Cómo impactan las condiciones operativas de la flota (tipo de vehículo, conductor, incidentes, mantenimiento) **sobre los tiempos de entrega y la satisfacción del cliente** en un operador de e-commerce?

Por que este problema

- Olist expone el *resultado* logístico (demoras, reseñas) pero no las *causas* operativas.
- Cruzar ambas fuentes permite pasar de descripción a causas.
- Decisiones concretas: mantenimiento preventivo, asignación de rutas, gestión de conductores.

Posibles tipo de análisis

- **Descriptivo:** patrones de demora por región y vehículo.
- **Predictivo:** modelo de riesgo de entrega tarde.
- **Prescriptivo:** recomendaciones de asignación.

El punto clave a comunicar: Olist solo nos dice "esta orden llego tarde y el cliente puso 2 estrellas". No nos dice POR QUE llego tarde. La flota sintética que construimos nos da la capa de causas: tipo de vehículo, comportamiento del conductor, nivel de riesgo de la ruta. La combinación de las dos fuentes es lo que hace interesante el proyecto. Mencionar brevemente que el dataset de flota es sintético pero calibrado con distribuciones reales de un dataset de Kaggle (dynamic supply chain logistics).

Los datos están en una base PostgreSQL local. La tabla central de vinculación es `fleet_deliveries` : `tiene una fila por cada orden de Olist con status = 'delivered'`, `con el vehiculo y conductor asignado, la distancia estimada, y las dos variables objetivo de los modelos especiales` `olist_geo_location` `con 1M de filas es el principal driver del / O en las consultas.`

Fuente 1: Olist (real, Kaggle)

Tabla	Filas
olist_geolocation	1.000.163
olist_orders	99.441
olist_order_items	112.650
olist_order_reviews	99.224
olist_order_payments	103.886
olist_customers + sellers	102.536
olist_products	32.952

Fuente 2: Flota (sintética calibrada)

Tabla	Filas
fleet_deliveries	96.470
fleet_incidents	3.574
fleet_maintenance	688
fleet_vehicles	60
fleet_drivers	40

Clave de vinculación: `fleet_deliveries.order_id = olist_orders.order_id`

SGBD: PostgreSQL 18 Total: ≈1,6 M registros Indices: 67 (DDL + covering indexes)

El dataset presentó 4 problemas.

Problema	Descripción	Solución propuesta
Coordenadas fuera de Brasil	42 de 1M registros en geolocation	Filtrar por bounding box en Etapa 2
Productos con peso = 0	4 registros con weight_g = 0	Imputar mediana
Ítems con producto inexistente	Productos eliminados del catálogo	Placeholder unknown_product
review_id duplicados	814 duplicados en CSV	Nueva PK interna review_pk

Este slide es importante para la evaluación: muestra que el grupo hizo un diagnostico de calidad de datos real, no solo cargamos los CSV y listo. Los 4 problemas son bugs conocidos del dataset Olist, no errores nuestros. Lo relevante académicamente es que los identificamos, documentamos la decisión de fix y dejamos registro para Etapa 2. Destacar que el `03c_postimport.sql` es el resumen directo del notebook de limpieza de Etapa 2.

5 preguntas analíticas

- **Q1:** ¿Qué factores operativos (`route_risk_level`, tipo de vehículo, `driver_behavior_score`) se asocian a las entregas demoradas, por estado de Brasil?
- **Q2:** ¿Existe relación entre el comportamiento del conductor y el score promedio de reseña del cliente?
- **Q3:** ¿En que meses se concentran los mantenimientos correctivos, y coincide con el pico de órdenes demoradas en Olist?
- **Q4:** ¿Qué tipos de incidente generan mayor impacto en horas de demora?
- **Q5:** ¿El costo de mantenimiento por tipo de vehículo se justifica con su rendimiento logístico?

Mencionar brevemente que estas 5 preguntas guían tanto las consultas SQL de Etapa 1 como los modelos predictivos de Etapa 3. Q2 anticipa el Modelo 2 (clasificación de `delivery_status`). Q3 valida la hipótesis de estacionalidad que construimos en el script de generación de `el_patron_nov-dic` de mantenimientos correctivos de `bera` a aparecer en los datos. Q5 es la consulta a 100 tablas de